

의료 영상 보고서 검색을 위한 정렬이 필요 없는 멀티모달 검색 증강 생성 방법



김연우¹ 한주혁¹ 김민재¹ 박지후² 이원희¹
¹ 경희대학교 소프트웨어융합학과 ² 경희대학교 컴퓨터공학과
{dusdn, hhannn, kmj5596, janett1005, whlee}@khu.ac.kr

Introduction

- 대규모 언어 모델(Large Language Model, LLM)은 충분한 데이터로 학습되지 않은 경우 낮은 전문성을 지니며 환각 문제를 야기
- 검색 증강 생성(Retrieval-Augmented Generation, RAG) 모델은 질문과 연관된 데이터를 검색하여 정확한 답변을 제공하며, 특히 신뢰성 높은 정보가 필수적인 의료 분야에서 유용 [1]
- RAG 모델은 이미지-텍스트와 같은 멀티모달 데이터 간 검색이 가능하도록 하지만, 모달리티 간 정렬 모델을 추가로 필요로 함 [2]
- 본 논문에서는 이미지-이미지 간 검색을 활용하여 멀티모달 RAG를 수행하는 정렬이 필요 없는 멀티모달 검색 증강 생성 방법을 제안

Methods

Datasets

- 매사추세츠 공과대학교에서 25,379명의 환자를 대상으로 수집한 MIMIC-CXR 데이터셋 [3]
- 본 연구에서는 ALBEF 모델의 사전 학습에 사용되지 않은 784명의 이미지-텍스트 쌍 데이터 사용 [4]
- CXR 이미지 7,227장과 의료 보고서 4,442개
- 데이터베이스 데이터셋과 질문에 사용할 데이터셋은 7:3 비율로 나누어 사용

Models

- 이미지-이미지 검색을 위한 의료 도메인 이미지 인코더 MedCLIP [5]
- MedCLIP은 CheXpert, MIMIC-CXR, COVID, RSNA Pneumonia 데이터셋으로 사전 학습됨 [3, 6, 7, 8]
- 이미지-텍스트 검색을 위한 이미지-텍스트 정렬 의료 도메인 멀티모달 인코더 ALBEF [4]
- ALBEF는 MIMIC-CXR 데이터셋으로 사전 학습됨 [3]
- 벡터 간 내적 기반 유사도를 계산하기 위한 고차원 벡터 유사성 검색 라이브러리 FAISS [9]




그림 1. 이미지-이미지 검색 모델 구조도

Methods

- 이미지-이미지 검색을 위해 MedCLIP 임베딩 모델을 이용하여 데이터베이스 CXR 이미지와 질문 CXR 이미지에 대한 512차원의 이미지 임베딩 벡터 추출
- 이에 대한 비교군으로 이미지-텍스트 검색을 위해 ALBEF 임베딩 모델을 이용하여 데이터베이스 의료 보고서와 질문 CXR 이미지에 대한 256차원의 텍스트 임베딩 벡터와 256차원의 이미지 임베딩 벡터 추출
- 질문 이미지 벡터와 데이터베이스 이미지/텍스트 벡터에 대한 내적을 수행하여 이미지-이미지/이미지-텍스트 간 유사도 측정
- 유사도 점수를 비교하여 top K개의 CXR 이미지를 특정하여 이와 쌍을 이루는 텍스트 의료 보고서를 최종 검색 결과로 반환 (K=6)
- 의료 텍스트 라벨링 모델 NegBio로 labeling 된 의료 보고서에 대한 multi-label classification 데이터를 사용하여 RAG 성능 평가

Results

- 성능 평가의 기준이 되는 multi-label classification 데이터는 의료 보고서의 텍스트를 14개의 label에 대한 4가지 클래스(-1, 0, 1, nan)를 판정해 기록한 데이터
- 이미지-이미지 검색 결과에서 정확도는 67.49%(비교군: 67.31%), F1-score는 35.85%(비교군: 35.65%)로, 비교군인 이미지-텍스트 검색 대비 우수한 성능을 보임
- Accuracy, precision, recall, F1-score가 각각 0.183%, 0.038%, 0.200%, 0.200% 향상

표 1. 검색 모델에 따른 성능 비교

Evaluation Metrics	Image-Image Retrieval	Image-Text Retrieval
Accuracy (%)	67.491 ± 8.753	67.308 ± 8.583
Precision (%)	36.949 ± 10.320	36.911 ± 9.820
Recall (%)	37.044 ± 9.374	36.844 ± 8.982
F1-score (%)	35.853 ± 9.499	35.653 ± 8.959

Conclusions

- 이미지 인코더(MedCLIP)만을 사용하여 이미지-이미지 유사도를 기반으로 텍스트를 검색하는 단순화된 멀티모달 RAG 모델을 제안
- 기존의 모달리티 간 정렬된 인코더(ALBEF)를 사용하는 검색 방식과 비교하여 검색 성능에 큰 차이가 없음을 실험을 통해 입증
- 정렬 모델 없이 RAG를 수행하는 이미지-이미지 유사도 기반 텍스트 검색 방식은 기존 멀티모달 RAG 모델보다 계산 복잡성을 줄이면서도 유사한 검색 성능을 제공하며, 의료 영상 보고서 검색의 정확성과 효율성을 향상시키는데 기여하고 더 효율적이고 확장 가능한 솔루션을 제공할 수 있을 것임

References

- [1] Lewis et al., Adv Neural Inf Process Syst, 2020
- [2] Ranjit et al., MLHC, 2023
- [3] Johnson et al., Scientific data, 2019
- [4] Li et al., Adv Neural Inf Process Syst, 2021
- [5] Wang et al., ArXiv, 2022
- [6] Irvin et al., Proc AAAI Conf Artif Intell, 2019
- [7] Rahman et al., Comput Biol Med, 2021
- [8] Shih et al., Radiol Artif Intell, 2019
- [9] Jégou et al., ASCL, 2022

"본 연구는 과학기술정보통신부 및 정보통신기획평가원의 2024년도 SW중심대학사업의 결과로 수행되었음"(2023-0-00042)